

Proyecto 1 — Obtención y Limpieza de los Datos

Establecimientos educativos de Guatemala (MINEDUC) — CC3066 Data Science,
Universidad del Valle de Guatemala

23 de julio de 2026

Proyecto 1. Obtención y Limpieza de los Datos

Curso: CC3066 — Data Science, Semestre II 2026 **Universidad del Valle de Guatemala, Facultad de Ingeniería, Departamento de Ciencias de la Computación**

Integrantes: Mario Rocha (23501), Juan Francisco Martínez (23617), Jonathan Zacarías (231104), Luis Pedro Lira (23669)

Repositorio: https://github.com/rocha30/DS_Proyecto_1.git

Entregables incluidos en el repositorio:

- Código de obtención (`scraping/`) y limpieza (`DPL/limpieza.py`, `DPL/duplicados_parciales.py`, `DPL/validacion.py`), y notebook de diagnóstico (`DPL/diagnostico.ipynb`).
- Datos crudos (`data/crudo/`, `data/dataset.csv`) y datos limpios (`data/dataset_limpio.csv`).
- Libro de códigos en markdown (`DPL/libro_codigos.md`) y en PDF (`DPL/libro_codigos.pdf`).
- Este documento (`Informe_Final_Proyecto1.md`), con el proceso completo: diagnóstico, plan de limpieza, limpieza aplicada, duplicados, validación e informe de calidad antes/después.

1. Obtención de los datos

Fuente: Sistema de consulta pública de establecimientos educativos del Ministerio de Educación de Guatemala (MINEDUC), http://www.mineduc.gob.gt/BUSCAESTABLECIMIENTO_GE/.

Método: web scraping con Playwright (Chromium). El sitio es un formulario ASP.NET WebForms protegido por Incapsula, que bloquea peticiones POST sin un navegador real, por lo que no se pudo usar `requests`. Se automatizó una búsqueda por cada uno de los 23 valores del dropdown de Departamento (los 22 departamentos oficiales de Guatemala más CIUDAD CAPITAL como entrada administrativa separada del propio formulario), dejando el resto de filtros (Municipio, Nivel, Sector, Plan, Modalidad) en TODOS para no perder registros por una interpretación restrictiva del alcance “hasta diversificado” pedido en el enunciado — el filtro de nivel se aplicó después, en la limpieza (ver §4).

Resultado: 23 archivos CSV crudos (uno por departamento) en `data/crudo/`, unidos en `data/dataset.csv` con `pd.concat` sin pérdida ni duplicación de filas.

Fecha de extracción: 21 de julio de 2026.

2. Diagnóstico del estado inicial (datos crudos)

Análisis completo con código y tablas en `DPL/diagnostico.ipynb`; resumen razonado en `CheckPoint.md` (Parte 1). Resultados clave:

2.1 Registros y variables

94,533 registros, 17 variables en el conjunto crudo unido (23 CSV departamentales).

2.2 Tipo de dato

Las 17 columnas se infieren como texto (`str`) — correcto en todos los casos: `CODIGO/DISTRITO` tienen guiones y ceros a la izquierda (perderían información como entero), `TELEFONO` no es una magnitud numérica, y el resto es texto/categorico. **No se encontraron variables con tipo de dato incorrecto** en el crudo.

2.3 Valores faltantes por variable

Variable	# faltantes reales	%	# faltantes disfrazados adicionales
DIRECTOR	27,739	29.34%	2,057 ("-----", "S/D", etc.)
TELEFONO	27,514	29.11%	133 ("S/D")
SUPERVISOR	10,702	11.32%	0
DISTRITO	10,694	11.31%	0
DIRECCION	863	0.91%	22
ESTABLECIMIENTO	15	0.02%	0
Resto (11 variables)	0	0%	0

Tokens de faltante disfrazado buscados: cadenas vacías, `"-"/"--"/"---` (guiones de largo variable), `".", ". .", "?", "N/A", "NA", "NULL", "None", "S/D", "SD", "SIN DATO(S)", "NO APLICA", "N.A."`.

Total de celdas faltantes (reales + disfrazadas) en el crudo: 79,739 de 1,607,061 celdas (4.96%). Variables con al menos un faltante: 6 de 17.

2.4 Valores únicos

`CODIGO` es único en las 94,533 filas (llave candidata). Variables categóricas sin variantes de mayúsculas/espacios escondiendo duplicados de categoría (verificado: `nunique()` no cambia al normalizar `strip().upper()`). Detalle completo por variable en `CheckPoint.md` §4.

2.5 Registros duplicados exactos

0 duplicados de fila exacta, 0 duplicados por `CODIGO`. Se encontraron **9,530 pares** con mismo `ESTABLECIMIENTO+DIRECCION` pero distinto `CODIGO` — no son errores por sí solos (un mismo plantel físico puede tener varios códigos por nivel/jornada/plan distintos); se dejaron para revisión, no se dedujeron en la limpieza.

2.6 Valores fuera de dominio o inconsistentes

`DEPARTAMENTO`: sin valores fuera del catálogo de 23 entradas del dropdown (22 departamentos + `CIUDAD CAPITAL`, que geográficamente es el mismo departamento de Guatemala — ver §4). `DISTRITO`: formato mixto, 79 valores incompletos ("01-", "17-", ...). `NIVEL`: incluye `UNIVERSIDAD` (1) y `ADMINISTRATIVOS` (2), fuera del alcance pedagógico “hasta diversificado” porque se consultó `Nivel=TODO`s durante el scraping.

2.7 Formatos inconsistentes

Variable	Problema	# afectados
<code>ESTABLECIMIENTO</code>	Espacios internos dobles o más	4,676
<code>DIRECCION</code>	Espacios internos dobles o más	2,163
<code>SUPERVISOR</code>	Espacios internos dobles o más	370
<code>DIRECTOR</code>	Espacios internos dobles o más	9,507
<code>DIRECTOR</code>	Placeholders de guiones de largo variable ("----", etc.)	~2,057
<code>TELEFONO</code>	Multivalor en una celda (, / ; // Y)	hasta 268
<code>TELEFONO</code>	Longitud dominante 8 dígitos; resto con guiones/otros formatos	66,091 de 8 dígitos vs. el resto
<code>DISTRITO</code>	Dos esquemas válidos (AA-BB-CCCC, AA-BBB) + 79 incompletos	28,849 + 79

6 variables con formato inconsistente en el crudo: `ESTABLECIMIENTO`, `DIRECCION`, `SUPERVISOR`, `DIRECTOR`, `TELEFONO`, `DISTRITO`.

2.8 Síntesis de problemas de calidad

1. Faltantes altos en DIRECTOR (~29%) y TELEFONO (~29%) — dato incompleto en origen, no error de scraping.
2. Faltantes disfrazados en varias columnas que `isnull()` no detecta.
3. DISTRITO y SUPERVISOR co-ausentes en las mismas filas — patrón estructural (estables sin distrito/supervisor asignado).
4. DISTRITO con formatos heterogéneos, no validable con un solo regex.
5. CIUDAD CAPITAL vs GUATEMALA: misma geografía administrativa partida en el dropdown de scraping.
6. Tildes inconsistentes entre DEPARTAMENTO (sin tildes) y DEPARTAMENTAL (con tildes).
7. Espacios dobles en 4 variables de texto libre.
8. TELEFONO multivalor en una misma celda.
9. Niveles UNIVERSIDAD/ADMINISTRATIVOS fuera del alcance pedagógico del proyecto.
10. Sin duplicados de fila ni de CODIGO.
11. Sin basura HTML en ninguna celda — el parseo del scraper quedó limpio.
12. Mismo nombre+dirección con varios códigos (9,530 pares) — esperado por niveles/jornadas/planes distintos.

3. Plan de limpieza

Para cada variable se documentó, **antes** de tocar el código: problema(s) encontrado(s), regla de corrección y por qué debería funcionar, y riesgos de la transformación. Tabla completa (17/17 variables) en `Checkpoint.md`, Parte 2. Resumen de las decisiones más delicadas:

Variable	Problema	Regla	Riesgo aceptado
DEPARTAMENTO	CIUDAD CAPITAL separado de GUATEMALA en el dropdown, mismo departamento real	Fusionar CIUDAD CAPITAL → GUATEMALA	Se pierde la distinción “capital vs. resto de Guatemala” a nivel de esta columna — mitigado porque MUNICIPIO (ZONA 1...ZONA 25) y DEPARTAMENTAL (GUATEMALA NORTE/SUR/ORIENTE/OCCIDENTE) preservan esa granularidad
NIVEL	Incluye UNIVERSIDAD(1) y ADMINISTRATIVOS(2), fuera del alcance “hasta diversificado”	Eliminar esas 3 filas	Pérdida de 3 registros (<0.01%) — debe quedar explícito que el dataset limpio no cubre esos niveles

Variable	Problema	Regla	Riesgo aceptado
TELEFONO	Multivalor en una celda, formatos mixtos	Tomar el primer candidato de exactamente 8 dígitos; si ninguno califica, NaN	Se descartan teléfonos adicionales de la misma celda — pérdida de información aceptada a cambio de una columna comparable
DIRECTOR / DIRECCION / ESTABLECIMIENTO / SUPERVISOR	Nulos disfrazados (guiones, S/D, SIN DATO, etc.), espacios dobles	Normalizar a NaN los tokens de “sin dato”; colapsar espacios múltiples. No se corrige ortografía ni contenido lingüístico real	Ninguno relevante — son artefactos de formato, no contenido
DISTRITO	Dos esquemas válidos + 79 incompletos	Validar contra ambos regex; incompletos → NaN	Se pierden 79 valores parciales sin intentar reconstruirlos — aceptable (<0.1%), debe quedar explícito que no se intentó imputar

Regla general del proyecto: no se corrige la ortografía de nombres de establecimientos ni direcciones — el texto debe quedar tal como está, solo se normaliza formato (espacios, mayúsculas, encoding).

Revisado y confirmado con el equipo (2026-07-21): las 3 decisiones más delicadas (fusión de CIUDAD CAPITAL, filtro de NIVEL, regla de teléfono) fueron implementadas directamente en código por un integrante del equipo; se revisaron y el equipo las dio por definitivas.

4. Limpieza aplicada

Implementada en `DPL/limpieza.py`, dividida en dos bloques de trabajo (estructura geográfica/identificación, y catálogos/contacto). Corre con `python limpieza.py` desde `DPL/` (`venv Proyecto1`).

4.1 Registro de transformaciones

Variable	Problema detectado	Transformación	Registros afectados	Justificación
CODIGO	Ninguno (0 fuera de formato)	Validación de formato ##-##-####-## (defensiva, sin corrección)	0	Confirma que el crudo ya cumplía el estándar
DEPARTAMENTO	CIUDAD CAPITAL separado de GUATEMALA	strip().upper() + unificación CIUDAD CAPITAL→GUATEMALA	7,594	DEPARTAMENTAL ya repartía ambas etiquetas en las mismas 4 direcciones — confirma que MINEDUC las trata como la misma unidad geográfica
DEPARTAMENTAL	Ninguno (tildes correctas)	strip().upper() , 0 se preservan tildes oficiales	0	Es la única variable con tildes correctas del catálogo; quitarlas perdería información
MUNICIPIO	Ninguno grave	strip().upper() + colapsar espacios múltiples	0	Normalización preventiva
DISTRITO	79 incompletos, formatos mixtos	Nulos disfrazados → NaN ; incompletos (no matchean los 2 regex válidos) → NaN	79	Un distrito truncado no es recuperable sin la fuente original
SUPERVISOR	Nulos disfrazados	strip().upper() + colapsar espacios; nulos disfrazados → NaN (antes de mayúsculas, ver §4.3)	370 espacios dobles corregidos	Mismo patrón estructural que DISTRITO
ESTABLECIMIENTO	4,676 espacios dobles	strip().upper() + colapsar espacios (nulos disfrazados → NaN antes de mayúsculas)	4,676	Artefacto de captura, no parte del nombre real

Variable	Problema detectado	Transformación	Registros afectados	Justificación
DIRECCION	887 nulos disfrazados (24 + 863 originales, + guiones largos), 2,163 espacios dobles	Nulos disfrazados (incl. "-", "--", "---") → NaN antes de mayúsculas; colapsar espacios	24 disfrazados + 2,163 espacios dobles	Artefactos de formato; no se expanden abreviaturas ni se corrige ortografía
DIRECTOR	29,796 faltantes (reales+disfrazados) 9,507 espacios dobles	Placeholders (guiones de largo variable, "SIN DATO(S)", "NO APLICA", encoding roto) → NaN antes de mayúsculas; colapsar espacios	2,321 celdas de texto convertidas a NaN + 9,507 espacios dobles	Guiones/tokens son evidentemente “sin dato” del sistema fuente, no nombres reales
TELEFONO	Multivalor, formatos mixtos	S/D/vacío → NaN; de celdas con separadores, primer candidato de 8 dígitos; si ninguno, NaN	853 celdas sin candidato válido → NaN	8 dígitos es el formato dominante y válido para Guatemala
NIVEL, SECTOR, AREA, STATUS, MODALIDAD, JORNADA, PLAN	NIVEL fuera de alcance (3 filas); AREA=“SIN ESPECIFICAR” (8)	<code>strip().upper()</code> ; eliminar filas de NIVEL fuera de alcance; AREA=“SIN ESPECIFICAR” → NaN	3 filas eliminadas + 8 celdas de AREA → NaN	El enunciado pide datos “hasta diversificado”; “SIN ESPECIFICAR” es un faltante disfrazado

4.2 Duplicados

Exactos: 0 duplicados de fila y 0 por CODIGO (confirmado también sobre el conjunto limpio).

Parciales (similitud de cadenas): implementado en `DPL/duplicados_parciales.py` con RapidFuzz (`token_sort_ratio`), bloqueo por (`DEPARTAMENTO,MUNICIPIO`) para acotar comparaciones, excluyendo los 9,530 pares ya contados como exactos. Con umbral final nombre 95 y dirección 90 (calibrado revisando muestras): **15,751 pares, agrupados en 4,018 grupos** (13,738 registros):

- **3,362 grupos** con nombre propio — candidatos de mayor confianza; el patrón dominante es el mismo plantel con varios niveles y una diferencia mínima de puntuación en la dirección (ej. "3A AVENIDA" vs "3A. AVENIDA").
- **656 grupos** con nombre genérico tipo sigla (EORM, EODP, etc.) — marcados aparte porque cientos de escuelas rurales distintas comparten ese nombre oficial abreviado; no implican que sean el mismo plantel.

Ningún registro fue eliminado ni fusionado automáticamente — el reporte completo (data/posibles_duplicados_parciales_grupos.csv) queda para revisión manual, según pide el enunciado.

4.3 Bug encontrado y corregido durante la limpieza

Al escribir las pruebas de validación (§5) se detectó que en `limpiar_supervisor`, `limpiar_direccion` y `limpiar_establecimiento` el `.str.upper()` se aplicaba **antes** de comparar contra los tokens de nulo (en minúscula); como `str(NaN).upper() == "NAN"`, la comparación nunca coincidía y esas tres columnas guardaban el texto literal "NAN" en vez de un valor faltante real — **10,701 casos en SUPERVISOR, 863 en DIRECCION, 15 en ESTABLECIMIENTO**. Se corrigió el orden (mapear nulos antes de pasar a mayúsculas) y se regeneró `dataset_limpio.csv`. De paso se completaron los tokens de nulo disfrazado que faltaban en DIRECCION (guiones largos) y DIRECTOR ("SIN DATO(S)", "NO APLICA").

5. Pruebas de validación del conjunto limpio

Implementadas en `DPL/validacion.py` (python `validacion.py`). Cada prueba imprime PASA/FALLA y termina con exit code 1 si alguna prueba dura falla.

Prueba	Resultado
Sin registros duplicados exactos	PASA
Sin duplicados por CODIGO	PASA
Sin espacios al inicio/final en texto	PASA
TELEFONO en formato consistente (8 dígitos o NaN)	PASA
CODIGO cumple ##-##-####-##	PASA
DISTRITO cumple uno de los 2 formatos válidos, o NaN	PASA
DEPARTAMENTO pertenece al catálogo de 22 departamentos	PASA
NIVEL sin categorías fuera de alcance	PASA
AREA sin "SIN ESPECIFICAR"	PASA
Sin categorías duplicadas por diferencias de escritura	PASA
Sin nulos disfrazados conocidos	PASA
(advertencia, no cuenta para el resultado)	ADVERTENCIA conocida (ver §6.1)
TELEFONO no se corrompe sin <code>dtype=str</code>	

Resultado: 11/11 pruebas pasan. Esta suite fue la que encontró el bug descrito en §4.3.

6. Informe de calidad: antes vs. después

Métrica	Antes (crudo)	Después (limpio)
Registros	94,533	94,530 (−3 por filtro de NIVEL fuera de alcance, ver §4.1)
Variables	17	17 (sin variables derivadas creadas ni columnas eliminadas)
Valores faltantes (celdas, reales + disfrazados)	79,739 (4.96%)	80,806 (5.03%, todos NaN reales — el leve aumento refleja nulos disfrazados que antes no eran detectables y ahora quedan explícitos, no nueva pérdida de datos)
Variables con al menos un NA	6 de 17	7 de 17 (AREA gana NaN por el mapeo deliberado de "SIN ESPECIFICAR")
Duplicados exactos	0	0
Posibles duplicados	9,530 pares (mismo nombre+dirección exactos; sin análisis de similitud de cadenas)	9,530 pares exactos + 4,018 grupos adicionales por similitud (13,738 registros) — ninguno eliminado/fusionado, todos documentados para revisión manual
Variables con formato inconsistente	6 (ESTABLECIMIENTO, DIRECCION, SUPERVISOR, DIRECTOR, TELEFONO, DISTRITO)	0 (validado por la suite de pruebas, §5)
Variables con tipo de dato incorrecto	0 (pandas ya infería correctamente <code>str</code> en las 17 columnas)	0 — con la advertencia documentada de que TELEFONO se corrompe a <code>float64</code> si el CSV se recarga sin <code>dtype=str</code> (§6.1)
Categorías inconsistentes	1 (DEPARTAMENTO: CIUDAD CAPITAL y GUATEMALA representaban la misma entidad geográfica)	0

Métrica	Antes (crudo)	Después (limpio)
Errores corregidos	—	27,598 en total: 3 registros eliminados (NIVEL fuera de alcance) + 3,285 nulos disfrazados normalizados (79 DISTRITO + 24 DIRECCION + 2,321 DIRECTOR + 853 TELEFONO + 8 AREA) + 16,716 espacios dobles colapsados (4,676 ESTABLECIMIENTO + 2,163 DIRECCION + 370 SUPERVISOR + 9,507 DIRECTOR) + 7,594 unificaciones de categoría (CIUDAD CAPITAL→GUATEMALA)

6.1 Limitación conocida y aceptada: TELEFONO y dtype

Tras la limpieza, TELEFONO quedó compuesta únicamente por dígitos (sin guiones). Si el CSV se recarga con `pd.read_csv` sin fijar `dtype`, pandas infiere la columna como `float64` y corrompe el valor (22324443 → 22324443.0). Se confirmó que ni siquiera `quoting=csv.QUOTE_NONNUMERIC` al guardar evita esto — pandas infiere el tipo por contenido al leer, sin importar las comillas. **Cargar siempre con `dtype=str`** (documentado también en el libro de códigos §2). No se cuenta como defecto de los datos, es una instrucción de uso obligatoria.

7. Generación del conjunto de datos limpio

`data/dataset_limpio.csv` — un solo archivo con la información de los 22 departamentos, 94,530 registros × 17 variables, estructura consistente, tipos de datos correctos, nombres de variable descriptivos, formato uniforme, y sin los errores detectados durante la validación (§5).

Cargar siempre así:

```
import pandas as pd
df = pd.read_csv("data/dataset_limpio.csv", encoding="utf-8-sig", dtype=str)
```

8. Libro de códigos

Documento completo en `DPL/libro_codigos.md` (y su versión en PDF, `DPL/libro_codigos.pdf`), con descripción, tipo de dato, dominio, valores posibles y tratamiento aplicado para cada una de las 17 variables, más notas y limitaciones conocidas.

9. Reproducibilidad

Todo el proceso es reproducible desde cero:

1. `scraping/03_scrape_all.py` → genera `data/crudo/*.csv`.
2. Unión de los 23 CSV → `data/dataset.csv` (ver `DPL/diagnostico.ipynb`).
3. `python DPL/limpieza.py` → genera `data/dataset_limpio.csv`.
4. `python DPL/duplicados_parciales.py` → genera `data/posibles_duplicados_parciales_grupos.csv`.
5. `python DPL/validacion.py` → corre las 11 pruebas de calidad.

Entorno: `venv Proyecto1/` (pandas, rapidfuzz, playwright).